GPT-2

Language Models are Unsupervised Multitask Learners

Alec Radford * 1 Jeffrey Wu * 1 Rewon Child 1 David Luan 1

[Submitted on 14 FEB 2019]

논문 구현

CloseAI팀 이상헌 이정훈 박준혁 김유철

30 May 2024

목차

GPT-1

GPT (Generative Pre-training Transformer)

기존 방법의 문제점

- Labeled Data의 양이 많지 않다 → 데이터 부족
- Unlabeled Data는 많지만 활용할 수 있는 방법 X

GPT-1가 제안한 방법

- Unlabeled Data를 사용한 Pre-Training
- Task에 맞게 Fine-Tuning

GPT (Generative Pre-training Transformer)

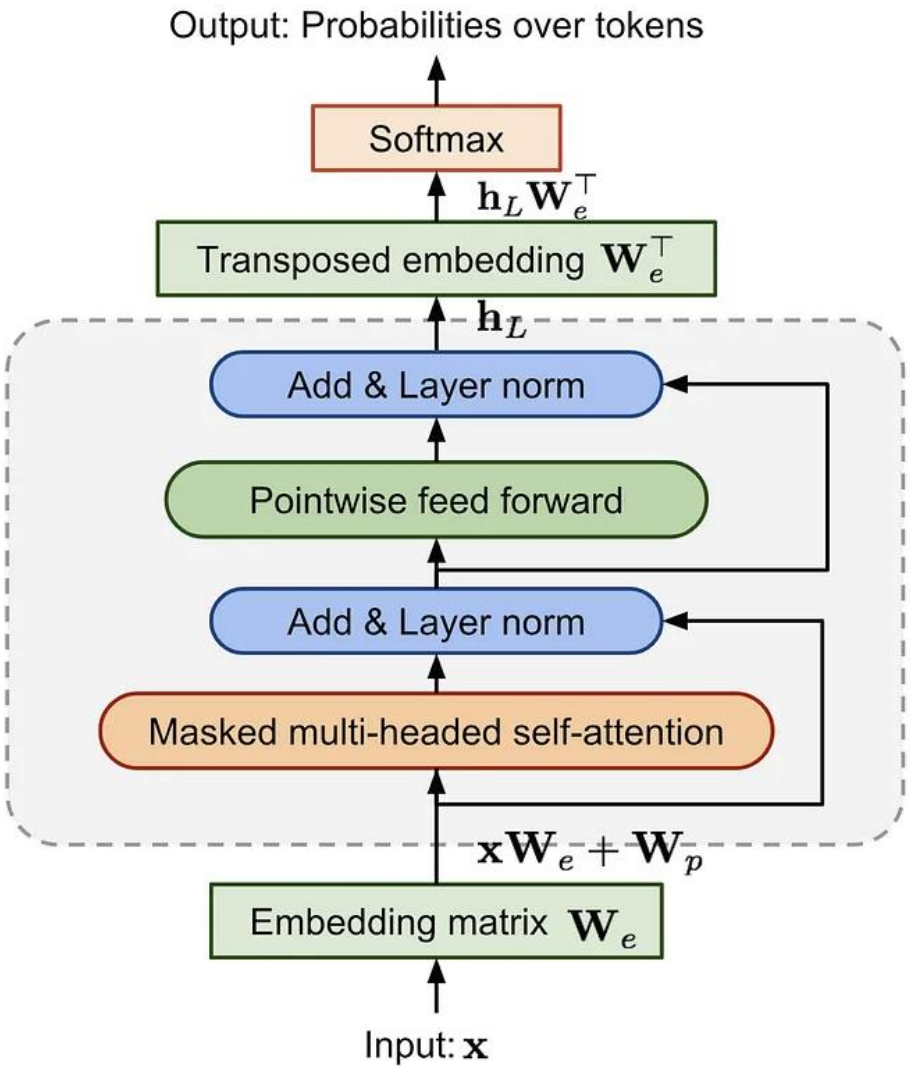

- Transformer의 디코더만 사용하는 구조
- 다음 단어를 맞추도록 학습

$$L_1(u) = \sum_i logP(u_i|u_{i-k}, \ldots, u_{i-1}; \theta)$$

$$L_2(C) = \sum_{(x,y)} logP(y|x^1, \ldots, x^m)$$

$$L_3(C) = L_2(C) + \lambda * L_1(C)$$

GPT (Generative Pre-training Transformer)

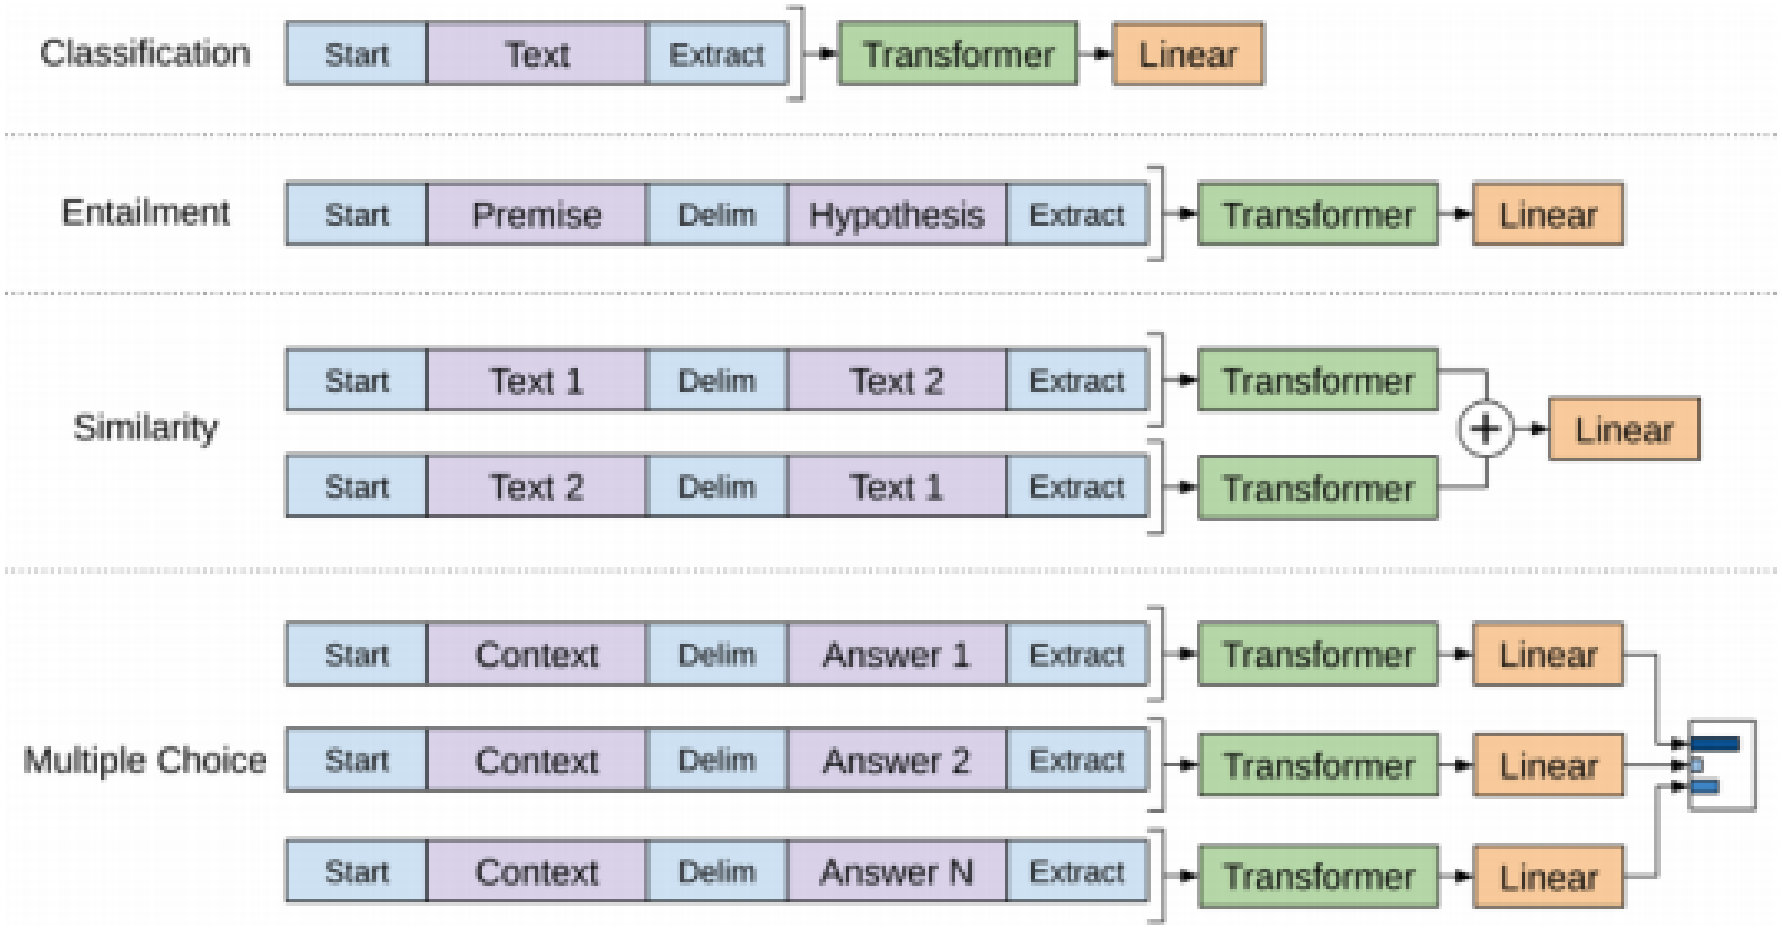

GPT (Generative Pre-training Transformer)

장점

- 전이학습의 효율성을 높였다
- Task 별 최소한의 엔지니어링
- 강력한 성능(SOTA)

단점

- 많은 계산량에서 야기되는 비싼 계산 비용
- Task 별 Fine-Tuning의 어려움(상대적)

BERT

BERT

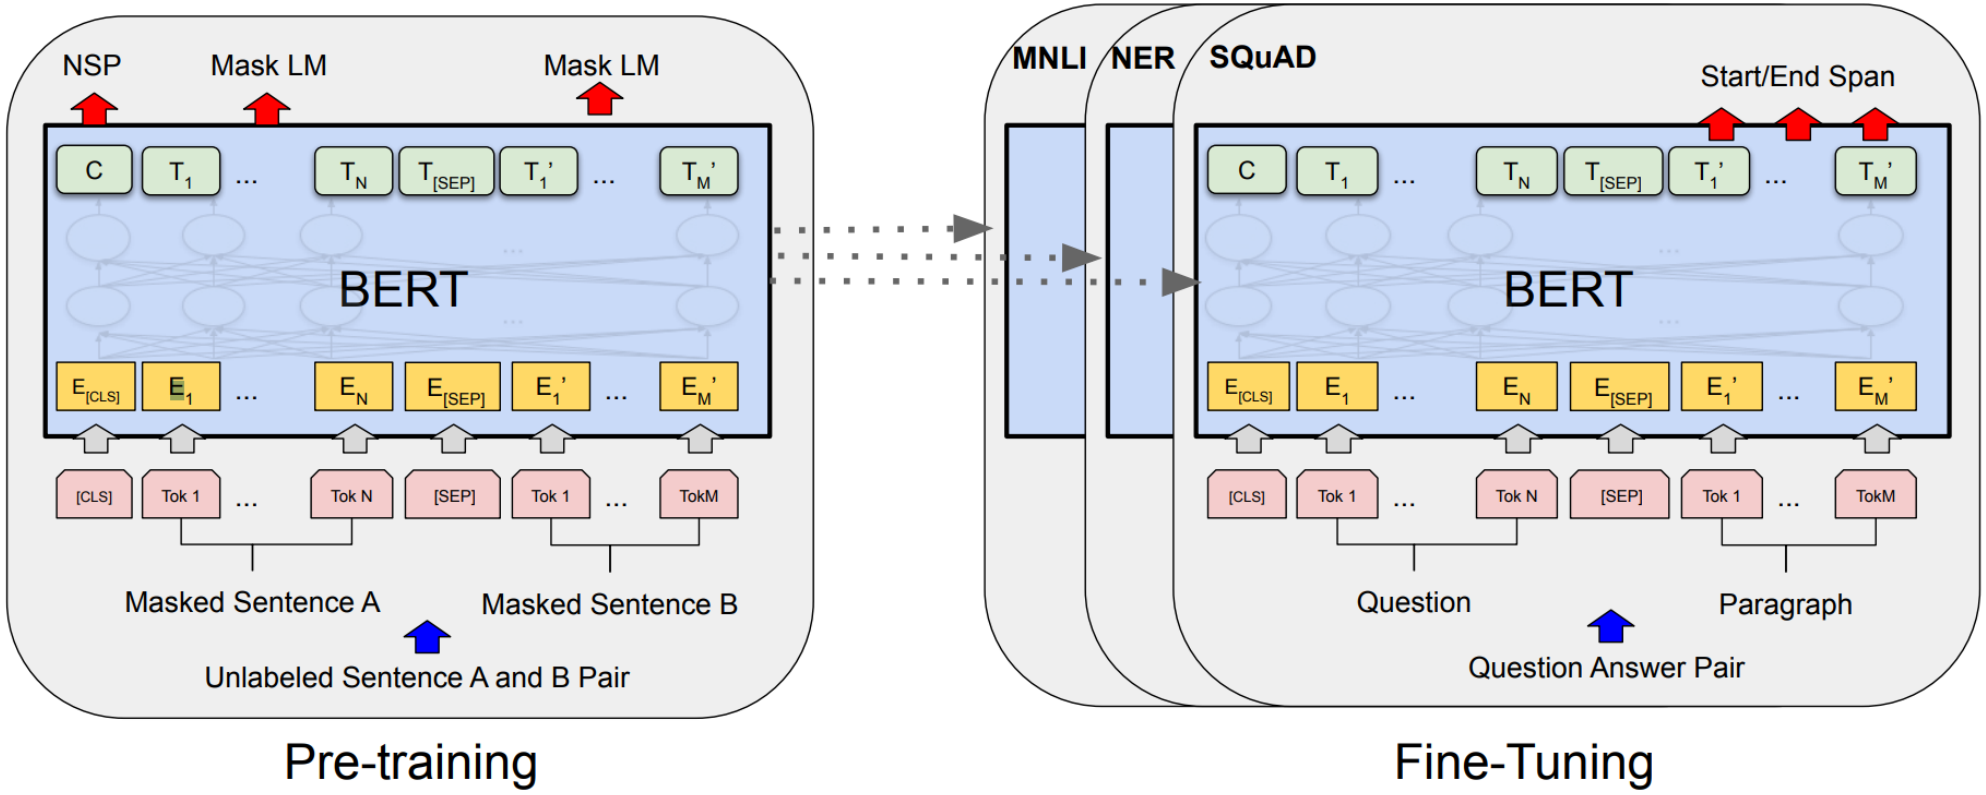

BERT (Bidirectional Encoder Representations from Transformers)

BERT

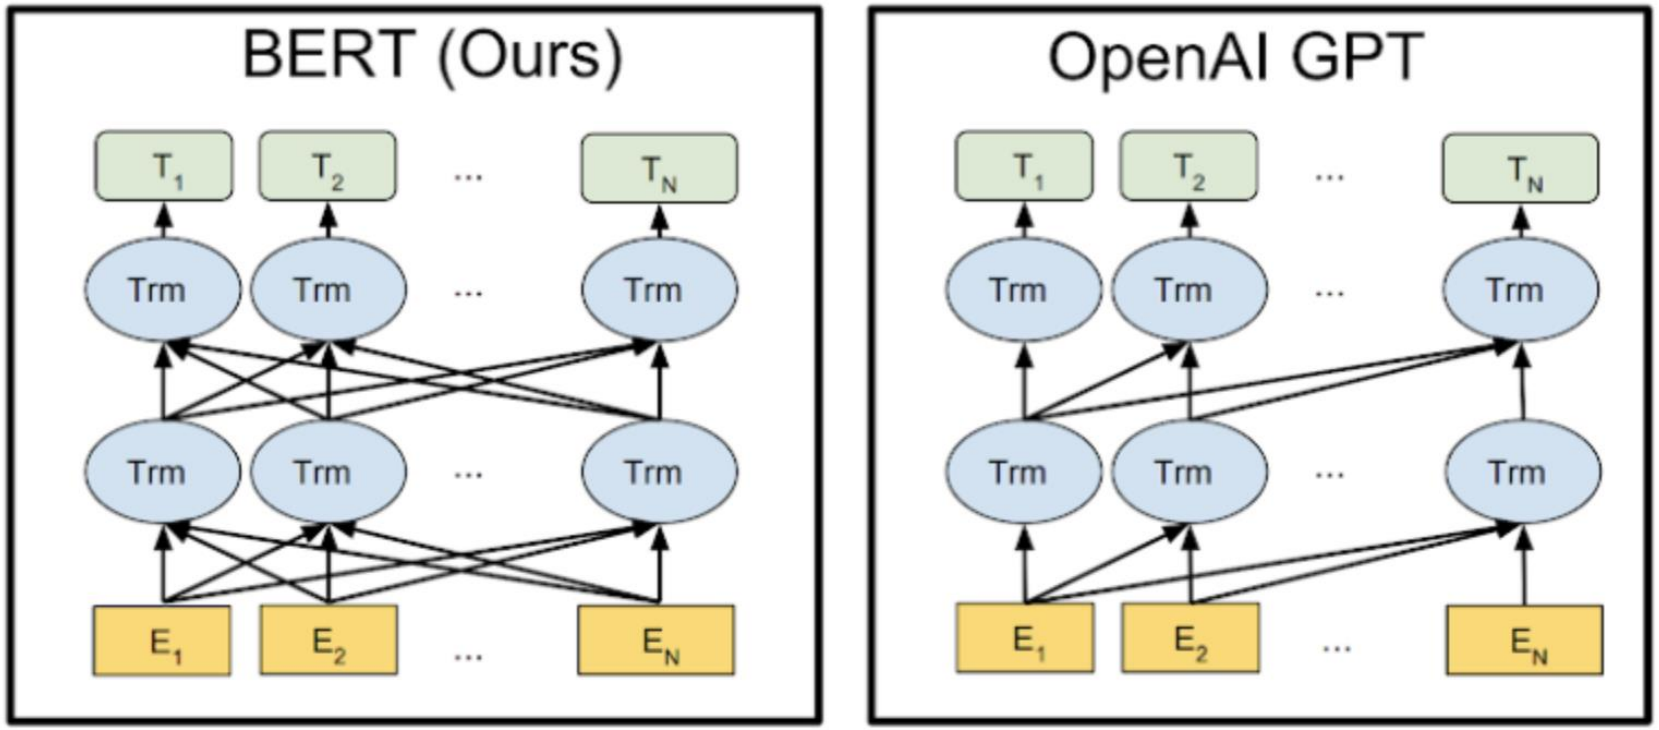

왼쪽에서 오른쪽으로 이동하도록 구성된 구조는 토큰이 이전에 나타난 토큰들에 대해서만 attend할 수 있다.

문맥을 양쪽에서 모두 이해해야 하는 question-answering task 에서 있어서 치명적

BERT

BERT

Encoder

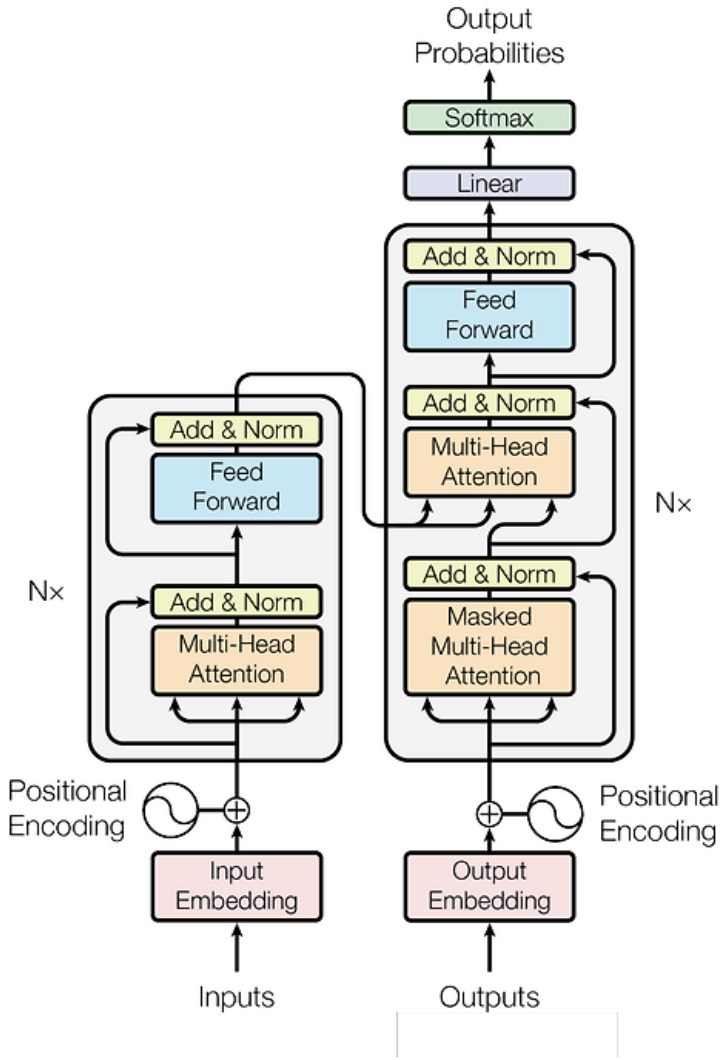

GPT

Decoder

BERT

Masked LM (MLM)

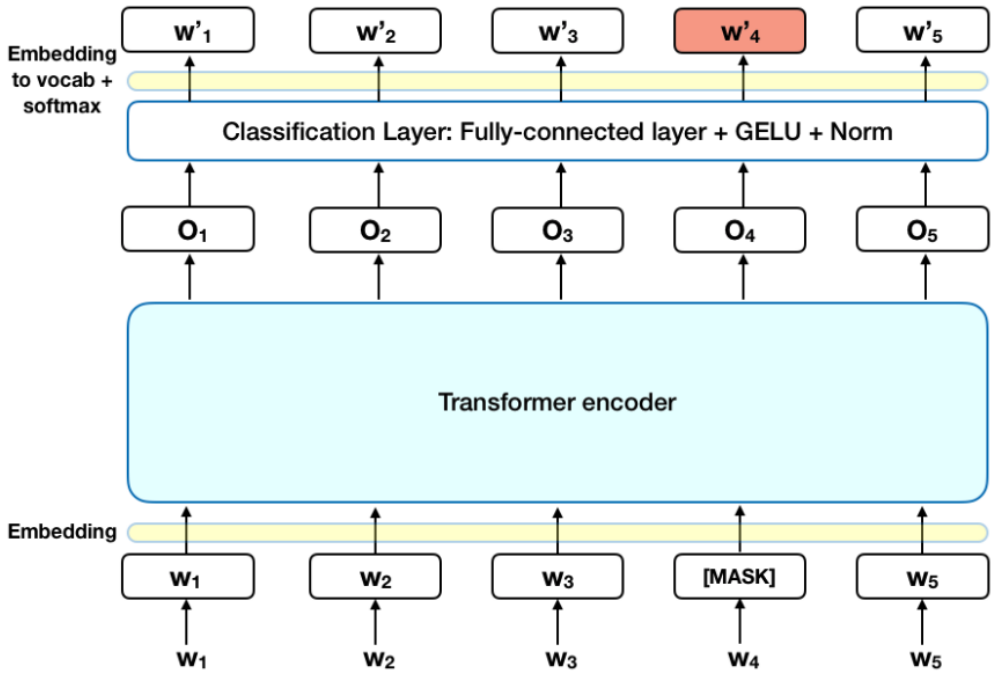

input tokens의 일정 비율을 마스킹하고
마스킹 된 토큰을 예측하는 과정

80% : token을 **[MASK] token으로** 바꾼다.
ex) my dog is hairy -> my dog is [MASK]

10% : token을 **random word로** 바꾼다.
ex) my dog is hairy -> my dog is apple

10% : token을 **원래 단어 그대로** 놔둔다.
ex) my dog is hairy -> my dog is hairy

$$L_{MLM}(\theta) = -\sum_{t \in M} \log P(x_t | x_{\setminus t}; \theta)$$

BERT

Next Sentence Prediction (NSP)

Question-answering(QA), Natural Language Interference(NLI) 등의 두 문장 사이의 관계를 이해해야 하는 task에 대해 학습시키기위해 NSP를 학습

모델은 두 문장 A, B를 입력으로 제공받는데,
절반은 두 번째 문장인 B는 실제로 A의 다음 문장으로 구성되고,
나머지 50%의 경우 B는 전혀 관계가 없는 임의의 문장으로 제공된다.
B가 다음 문장인 경우 IsNext, 임의의 문장인 경우 NotNext 라고 라벨링 하게 된다

GPT-2

GPT-2 (Generative Pre-training Transformer)

GPT-1 문제점

- Pre-Training + Fine-tuning의 방법으로 개발된 모델들은 데이터의 분포가 바뀌면 불안정해진다
- 특정 Task에서만 뛰어난 능력을 발휘한다

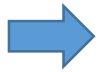

많은 Task에 적용 가능한 더 범용적인 모델을 개발할 필요성

GPT-2 (Generative Pre-training Transformer)

1. 고품질의 데이터

사람에 의해 필터링된 글만을 사용했다.

- Reddit에서 3 karma 이상을 받은 글에 포함된 외부 링크의 글을 가져옴
- 45M 개의 링크를 가져옴
- 2017년 12월 이후의 글과 위키피디아 글은 제거함 :
  위키피디아는 다른 dataset에서 흔하고, training과 test 단계에서의 데이터가 겹치는 문제로 인해 분석이 복잡해질 수 있기 때문에 제외했다.
- 중복제거 등을 거쳐 8M 개의 문서, 40GB의 텍스트를 확보

GPT-2 (Generative Pre-training Transformer)

2. Byte Pair Encoding (BPE) :

글자(byte)와 단어의 적당한 중간 단위를 쓰는 방식

자주 나오는 symbol sequence의 단어 수준 입력과

자주 나오지 않는 symbol sequence의 글자수준 입력을 적절히 보간

BPE는 subword 기반의 인코딩 방법으로 문자 단위로 단어를 분해하여 Vocabulary를 생성하고, 반복을 통해 빈도수가 높은 문자 쌍을 지속적으로 Vocabulary에 추가하는 bottom-up방법이다(Greedy).
예를 들자면,

$$Vocab_{word} = \{appel, avaliable, capable\}$$

$$Vocab_{char} = \{a, p, l, e, v, i, b, c, p\}$$

우선 {apple, available, capable} 로 구성된 Word Vocabulary로 부터 Character vocabulary {a,p,l,e,v,i,b,c,p}를 얻는다.
그 후, 매 회 반복을 통해 le, ble, able과 같이 함께 자주 등장하는 문자 쌍을 Character vocabulary에 greedy 하게 추가하는 방법이다.

$$Vocab_{BPE} = \{a, p, l, e, v, i, b, c, p, le, ble, able\}$$

예상되는 결과는 반복에 따라 {a, p, l, e, v, i, b, c, p, le, ble, able}과 같은 vocabulary가 완성될 것이다.

GPT-2 (Generative Pre-training Transformer)

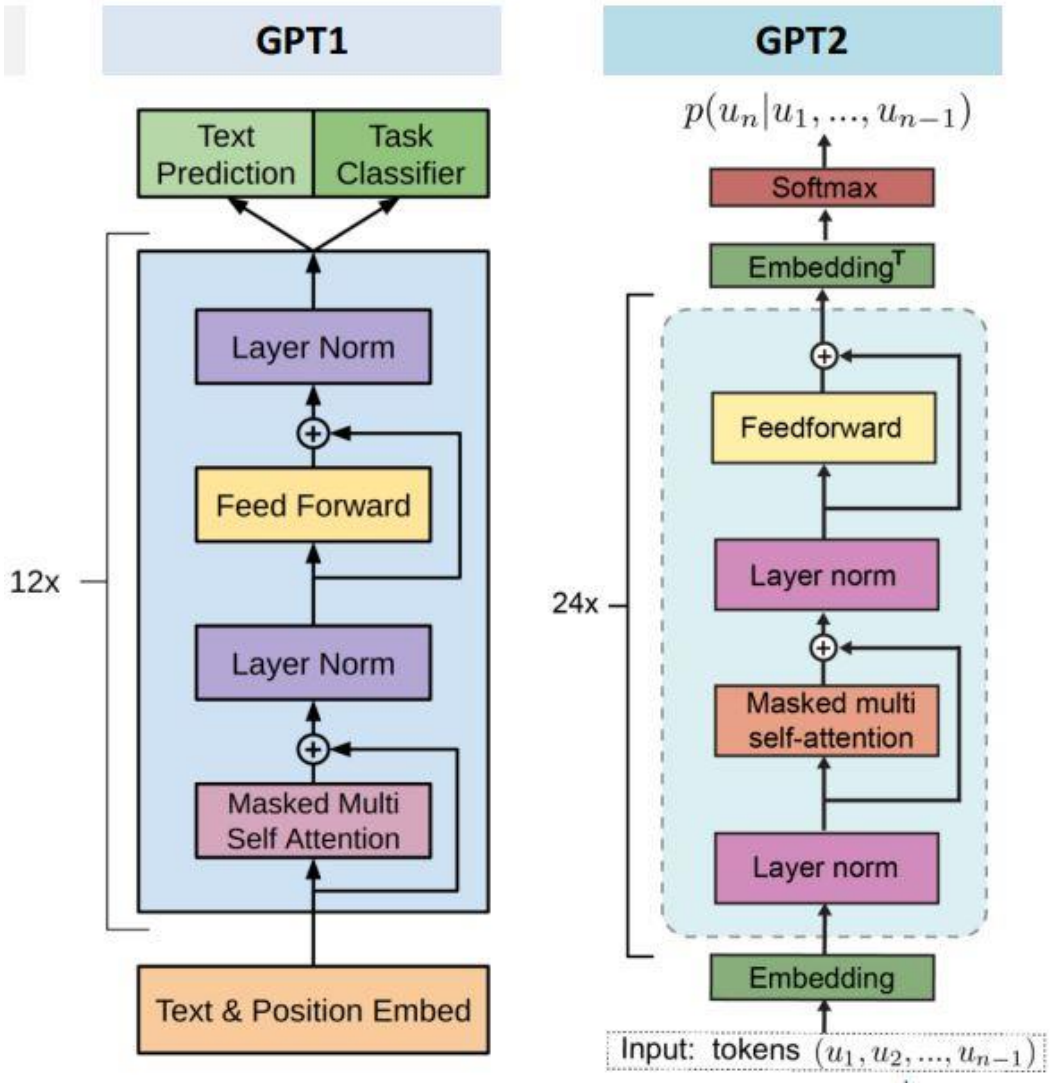

3. 모델 수정

- Layer Norm의 위치를 어텐션 블록 앞으로 이동
- 사전의 단어수 50,257개로 확장
- 문맥 고려 범위(context size)가 512 → 1024 개의 token으로 증가
- batch size = 512로 증가

논문 구현

논문 구현


```python
def model(hparams, X, past=None, scope='model', reuse=False):
    # 모델 스코프 정의, 재사용 설정 가능
    with tf.variable_scope(scope, reuse=reuse):
        results = {}  # 결과를 저장할 딕셔너리 초기화
        batch, sequence = shape_list(X)  # 입력 X의 배치 크기와 시퀀스 길이 추출

        # 위치와 토큰 임베딩을 위한 변수 생성
        wpe = tf.get_variable('wpe', [hparams.n_ctx, hparams.n_embd],
                              initializer=tf.random_normal_initializer(stddev=0.01))
        wte = tf.get_variable('wte', [hparams.n_vocab, hparams.n_embd],
                              initializer=tf.random_normal_initializer(stddev=0.02))
        # 과거 시퀀스 길이 계산
        past_length = 0 if past is None else tf.shape(past)[-2]
        # 입력 X에 대한 토큰 및 위치 임베딩 적용
        h = tf.gather(wte, X) + tf.gather(wpe, positions_for(X, past_length))

        # 트랜스포머 레이어를 위한 준비
        presents = []  # 각 레이어의 출력을 저장할 리스트
        pasts = tf.unstack(past, axis=1) if past is not None else [None] * hparams.n_layer  # 과거 데이터 언패킹
        assert len(pasts) == hparams.n_layer  # 레이어 수 검증
        for layer, past in enumerate(pasts):
            # 각 레이어를 순회하면서 트랜스포머 블록 적용
            h, present = block(h, 'h%d' % layer, past=past, hparams=hparams)
            presents.append(present)  # 현재 레이어의 출력 저장
        results['present'] = tf.stack(presents, axis=1)  # 모든 레이어의 출력을 스택하여 결과에 추가
        h = norm(h, 'ln_f')  # 마지막 레이어의 출력 정규화

        # 언어 모델 로스 계산을 위한 로짓 생성
        h_flat = tf.reshape(h, [batch*sequence, hparams.n_embd])  # 2D로 재배열
        logits = tf.matmul(h_flat, wte, transpose_b=True)  # 임베딩 가중치를 사용한 로짓 계산
        logits = tf.reshape(logits, [batch, sequence, hparams.n_vocab])  # 원래 차원으로 재배열
        results['logits'] = logits  # 로짓 결과 저장
        return results  # 최종 결과 반환
```

논문 구현


```python
def generate_text(prompt, max_length=1000, num_return_sequences=1, top_k=50, top_p=0.95):
    input_ids = tokenizer.encode(prompt, return_tensors='pt')

    # GPU가 사용 가능한 경우 GPU로 모델을 이동
    if torch.cuda.is_available():
        model.to('cuda')
        input_ids = input_ids.to('cuda')

    # 텍스트 생성
    with torch.no_grad():
        output = model.generate(
            input_ids,
            max_length=max_length + len(input_ids[0]), # 입력 길이 포함하여 최대 길이 설정
            num_return_sequences=num_return_sequences,
            pad_token_id=tokenizer.eos_token_id,
            do_sample=True,           # 샘플링 사용
            top_k=top_k,              # top_k 샘플링
            top_p=top_p               # top_p 샘플링
        )

    # 결과 디코딩 및 출력
    generated_texts = [tokenizer.decode(output[i], skip_special_tokens=True) for i in range(num_return_sequences)]

    # 프롬프트 부분을 제거하고 답변만 반환
    generated_responses = [text[len(prompt):].strip() for text in generated_texts]
    return generated_responses
```

논문 구현


```python
import os
from dotenv import load_dotenv
import openai

# Load environment variables from .env file
load_dotenv()

# Set API key
openai.api_key = os.getenv("OPENAI_API_KEY")

response = openai.ChatCompletion.create(
  model="gpt-3.5-turbo",
  messages=[
    {"role": "system", "content": "You are a helpful assistant."},
    {"role": "user", "content": "스타벅스 창립자의 정보를 알려줘"}
  ]
)

print(response['choices'][0]['message']['content'])
```

구현 결과

GPT-2 구현결과

```
프롬프트 : What is president's name?
==================================================
생성 결과: "My name is Donald Trump, a businessman, an American politician and my business partner at one time." In 2012, Trump went on Twitter to declare victory after running for president. He was, o
f course, elected in 2012 and is now running for reelection.
I am now a candidate for president of the United States. I have worked at CVS, McDonald's, UPS, and the National Guard, and I will fight to ensure every American has access to healthcare coverage and h
ealth coverage
```

GPT-3.5 API 사용결과

```
PS C:\Playground>  c:; cd 'c:\Playground'; & 'c:\Users\AIA\anaconda3\envs\gpt3_env\python.exe' 'c:\Users\AIA\.vscode\extensions\ms-python.debugpy-2024.6.0-win32-x64\
bundled\libs\debugpy\adapter/../..\debugpy\launcher' '61168' '--' 'c:\Playground\study\gpt\gpt3.py'
The current President of the United States is Joseph R. Biden Jr.
```

Reference

- **Improving Language Understanding by Generative Pre-Training (GPT-1)**

  Alec Radford/ 11 JUN 2018

- **BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding**

  Jacob Devlin/ 24 May 2019

- **Language Models are Unsupervised Multitask Learners**

  Alec Radford/ 14 FEB 2019

Q & A